

Prédiction des Maladies Cardiaques par Machine Learning

Modèle Prédicatif : Sain vs Maladie Cardiaque

Projet Final - Formation Data Analyst, DataSuits, Panthéon Sorbonne
Université Paris 1

Sommaire

Movitation

Definition des
variables

Distribution
des variables

Correlations
entre
variables

Methodologie

Résultats

Conclusion

Motivation



Problème Urgent

Les maladies cardiovasculaires sont la principale cause de mortalité mondiale, selon la OMS.



Enjeu Majeur

Détection précoce et prévention des risques cardiaques sont cruciales.



Solution Innovante

Développer un modèle prédictif utilisant le machine learning.



Antécédents de maladies cardiaques

Volonté de mieux comprendre cette pathologie.




Variables de la base de données

Feature	Description	Valeurs
age	Âge du patient (en années)	Numérique
sex	Sexe du patient	1 = homme, 0 = femme
cp	Type de douleur thoracique	0: Angine typique 1: Angine atypique 2: Douleur non-anginale 3: Asymptomatique
trestbps	Pression artérielle au repos (mm Hg)	Numérique
chol	Taux de cholestérol sérique (mg/dL)	Numérique
fbs	Glycémie à jeun	1: > 120 mg/dL 0: ≤ 120 mg/dL
restecg	Résultats ECG au repos	0: Normal 1: Anomalie onde ST-T 2: Hypertrophie ventriculaire gauche
thalach	Fréquence cardiaque maximale atteinte	Numérique
exang	Angine induite par l'exercice	1: Oui, 0: Non
oldpeak	Dépression ST induite par l'exercice	Numérique
slope	Pente du segment ST à l'effort maximal	0: Ascendante 1: Plate 2: Descendante
ca	Nombre de vaisseaux colorés par fluoroscopie	0-4
thal	Thalassémie	0-3
target	Variable cible - Maladie présente ou non	1: Oui, 0: Non


Distribution des Variables

Âge des Patients





La majorité des patients se situent entre 50 et 60 ans.
L'âge est un facteur de risque connu.

Proportion FBS > 120mg/dL




Seule une petite proportion de patients a une glycémie à jeun élevée. Cela indique que ce n'est pas le facteur prédominant.

Vérification de valeurs aberrants




- Possibles valeurs aberrantes dans les variables : trestbps, chol et oldpeak.
- Après vérification avec l'évidence scientifique, on confirme qu'il n'y a pas de valeurs outliers.


Distribution des Patients: Maladie Cardiaque




Distribution des Maladies Cardiaques par Sexe




Distribution du Type de Douleur Thoracique



Type de Douleur Thoracique par sexe



État de tension artérielle par sexe



Tension artérielle systolique standardisée selon les données scientifiques et les tranches d'âge, avec une marge de ± 5 mmHg.

Matrice de Corrélation des Variables Prédictives



- **-1** : Corrélacion négative forte
- ◆ **-0.5** : Corrélacion négative modérée
- **0** : Aucune corrélation
- ◆ **+0.5** : Corrélacion positive modérée
- **+1** : Corrélacion positive forte

Correlation entre variables indépendantes et la variable cible

Variable	Correlation
Cp	0.4349
Thalach	0.4229
Slope	0.3455
Thal	-0.3378
Ca	-0.3820
Exang	-0.4380
Oldpeak	-0.4384

- Corrélation $\neq$ Causalité
- La causalité implique qu'un **changement dans une variable provoque un changement dans une autre**. C'est une relation de cause à effet.
- L'association désigne une **relation statistique** entre deux variables : lorsqu'une variable change, l'autre a tendance à changer aussi.

Methodologie Machine Learning

Random Forest

Modèle d'ensemble utilisant plusieurs arbres de décision

- Excellentes performances sur de grands ensembles de données
- Gère efficacement la non-linéarité

KNN (K-Nearest Neighbors)


Classifie les points en fonction des K voisins les plus proches

- Efficace pour les petits ensembles de données numériques
- Sensible à la mise à l'échelle des variables


Regression Logistique

Modèle linéaire pour estimer la probabilité d'un événement binaire


- Idéal pour la classification binaire
- Interprétable et rapide à entraîner



Performances des modèles par métriques



Courbe ROC - Comparaison des modèles



AUC	Interprétation
0.90 – 1.00	Excellent
0.80 – 0.90	Très bon
0.70 – 0.80	Correct
0.60 – 0.70	Faible
0.50 – 0.60	Mauvais (quasiment aléatoire)
< 0.50	Pire que le hasard

Conclusion



Résultats

Modèle prédictif avec 98,5% de précision



Optimisation des ressources

Réduction des test de dépistage.



Perspectives d'Évolution

Enrichissement du dataset, intégration de nouvelles variables



Implementation Futures

Carte interactive des maladies cardiaques en France



Merci pour votre
attention.
Je suis à votre disposition
pour répondre à vos
questions.

